# Análisis de Segmentación Nutricional en Europa: Ejercicio 2

Irwin Alberto Viteri Rambay

2026-03-01

## Contents

**1 Introducción** **2**

**2 Preprocesamiento y Preparación de Datos** **2**

**3 (a) Análisis de Clústeres Jerárquicos Aglomerativos** **2**

**4 Interpretación y Selección del Método** **3**

**5 (b) Particionamiento Alrededor de Medoides (PAM)** **4**

**6 Análisis de Siluetas** **4**

**7 (c) K-means y Optimización vía Wilks' Lambda** **5**

**8 Conclusiones** **6**

**9 Repositorio** **6**

# 1 Introducción

El presente informe técnico aborda el problema de la segmentación de 25 naciones europeas basándose en sus patrones de consumo de proteínas en 9 grupos alimenticios. Utilizando técnicas de **Aprendizaje No Supervisado**, se busca identificar estructuras latentes que agrupen países con dietas similares, permitiendo una interpretación geográfica y nutricional robusta. El flujo de trabajo abarca desde el preprocesamiento con escalamiento Z-score hasta la validación avanzada mediante el estadístico $\Lambda$ de Wilks.

# 2 Preprocesamiento y Preparación de Datos

Para garantizar que las variables con mayores magnitudes no sesguen los algoritmos de distancia, se aplicó una estandarización de los datos.

```r
# Ingesta de datos crudos
protein_raw <- read.table(path_raw, header = TRUE, sep = "", check.names = FALSE)

# Limpieza de cabeceras mediante Regex
colnames(protein_raw) <- gsub("\\.", "", colnames(protein_raw))

# Selección de variables numéricas y escalado (Z-score)
protein_numeric <- protein_raw[, 4:13]
rownames(protein_numeric) <- protein_raw$country
protein_scaled <- scale(protein_numeric)
```

# 3 (a) Análisis de Clústeres Jerárquicos Aglomerativos

Se evaluaron cuatro métodos de vinculación para determinar la estructura de agrupación más natural de los datos.

```r
dist_matrix <- dist(protein_scaled, method = "euclidean")
methods <- c("average", "single", "complete", "ward.D2")

par(mfrow = c(2, 2))
for(m in methods) {
  hc <- hclust(dist_matrix, method = m)
  plot(hc, main = paste("Método:", m), xlab = "Países", sub = "", cex = 0.7)
}
```

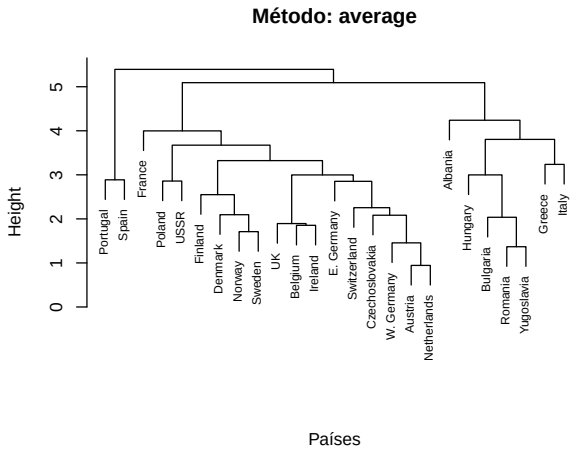


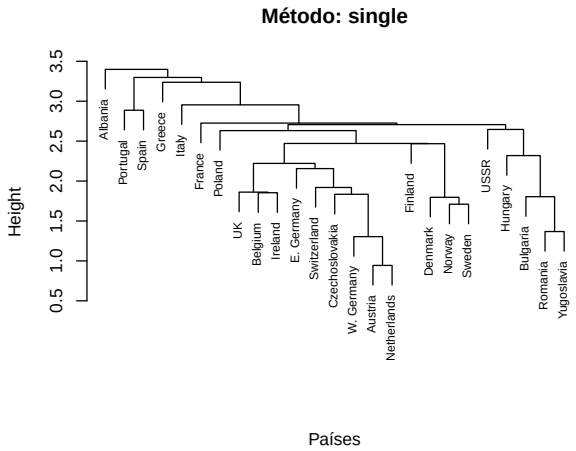


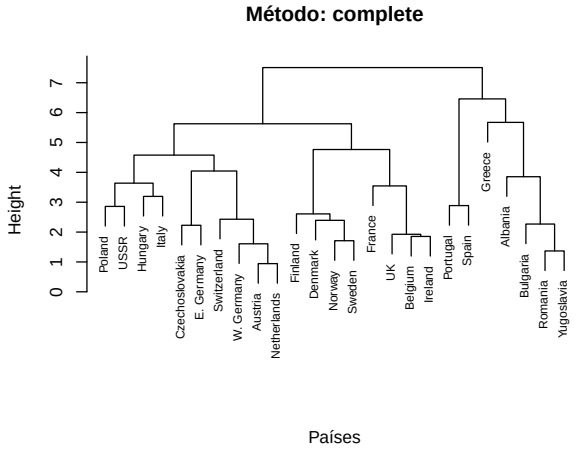

# 4 Interpretación y Selección del Método

- **Decisión de Clústeres**: Basado en los dendrogramas (especialmente el de Ward.D2 y Average), se observa una partición clara en $K = 3$ **clústeres**.
- **Interpretación de Grupos ($K = 3$)**:
  1. **Bloque Escandinavo/Europa Occidental**: Países con alto consumo de leche y pescado (e.g., Noruega, Dinamarca).
  2. **Bloque Mediterráneo**: Caracterizado por el consumo de frutas, vegetales y aceite/frutos secos (e.g., España, Portugal, Grecia).
  3. **Bloque de Europa del Este**: Mayor dependencia de cereales y carnes específicas (e.g., Bulgaria, Rumania).
- **Método Preferido**: Se selecciona **Ward.D2**. A diferencia de Single Linkage (que presenta encadenamiento), Ward maximiza la cohesión interna minimizando la varianza total dentro de los grupos, facilitando una interpretación espacial más nítida.

# 5 (b) Particionamiento Alrededor de Medoides (PAM)

Utilizando $K = 3$, aplicamos el algoritmo PAM, el cual es más robusto ante valores atípicos que K-means tradicional.

```
set.seed(42)
pam_res <- pam(protein_scaled, k = 3)

# Visualización en el Espacio de Componentes Principales (PCA)
fviz_cluster(pam_res, data = protein_scaled,
             main = "Segmentación PAM en Espacio PCA (Dim1: 41.3%, Dim2: 17.4%)")
```

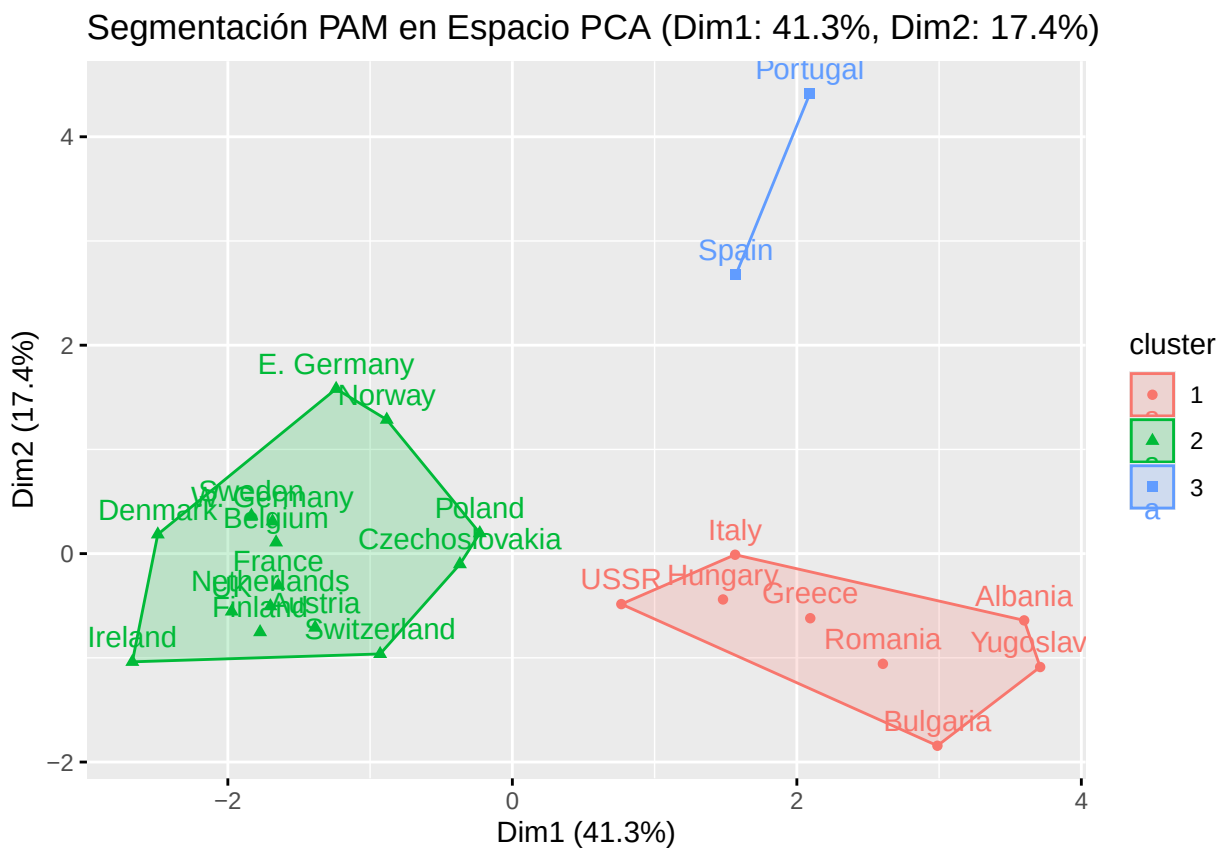


# 6 Análisis de Siluetas

La métrica de silueta mide qué tan bien se ajusta cada país a su clúster asignado.

```
fviz_silhouette(pam_res)
```

```
  cluster size ave.sil.width
1       1    8          0.25
2       2   15          0.36
3       3    2          0.43
```

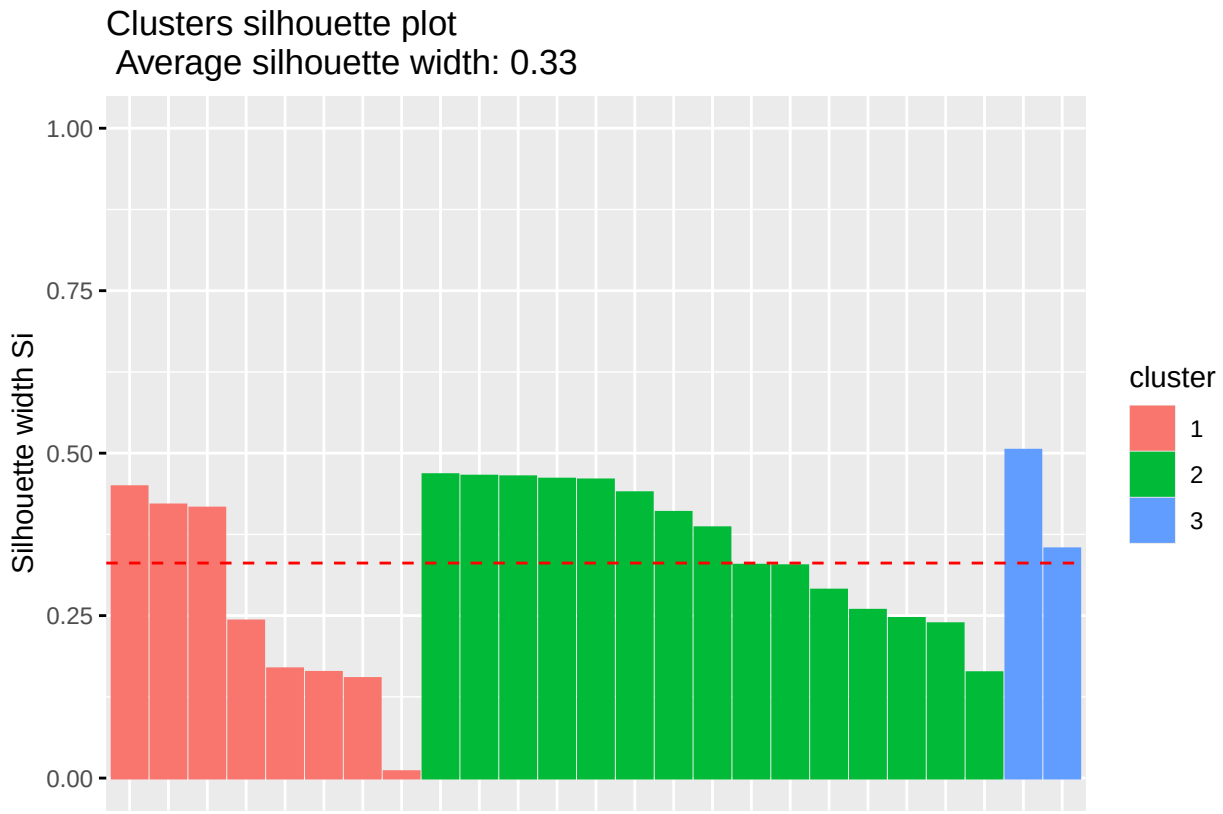


El ancho de silueta promedio es de 0.33. El Clúster 3 presenta la mayor solidez (0.43), mientras que el Clúster 2 es el más extenso con 15 países. Un valor positivo en casi todas las observaciones confirma que la estructura de 3 grupos es adecuada, aunque algunos países en las fronteras de los grupos presentan siluetas bajas, indicando perfiles dietéticos híbridos.

# 7 (c) K-means y Optimización vía Wilks' Lambda

Para validar el número óptimo de clústeres desde una perspectiva de varianza multivariante, se utilizó el estadístico $\Lambda$ de Wilks tras una reducción de dimensionalidad con PCA.

```
# Reducción de dimensionalidad para evitar problemas de rango en MANOVA
pca_res <- prcomp(protein_scaled)
data_pca <- pca_res$x[, 1:4]

calculate_wilks <- function(k, data) {
  set.seed(123)
  km <- kmeans(data, centers = k, nstart = 25)
  fit <- manova(as.matrix(data) ~ as.factor(km$cluster))
  return(summary(fit, test = "Wilks")$stats[1, 2])
}

ks <- 2:6
wilks_stats <- sapply(ks, function(x) calculate_wilks(x, data_pca))

# Visualización del Criterio de Wilks
```

```r
plot(ks, wilks_stats, type = "b", pch = 19, col = "darkblue",
     xlab = "Número de Clústeres (k)", ylab = "Wilks' Lambda",
     main = "Optimización de Clústeres: Criterio de Wilks")
```

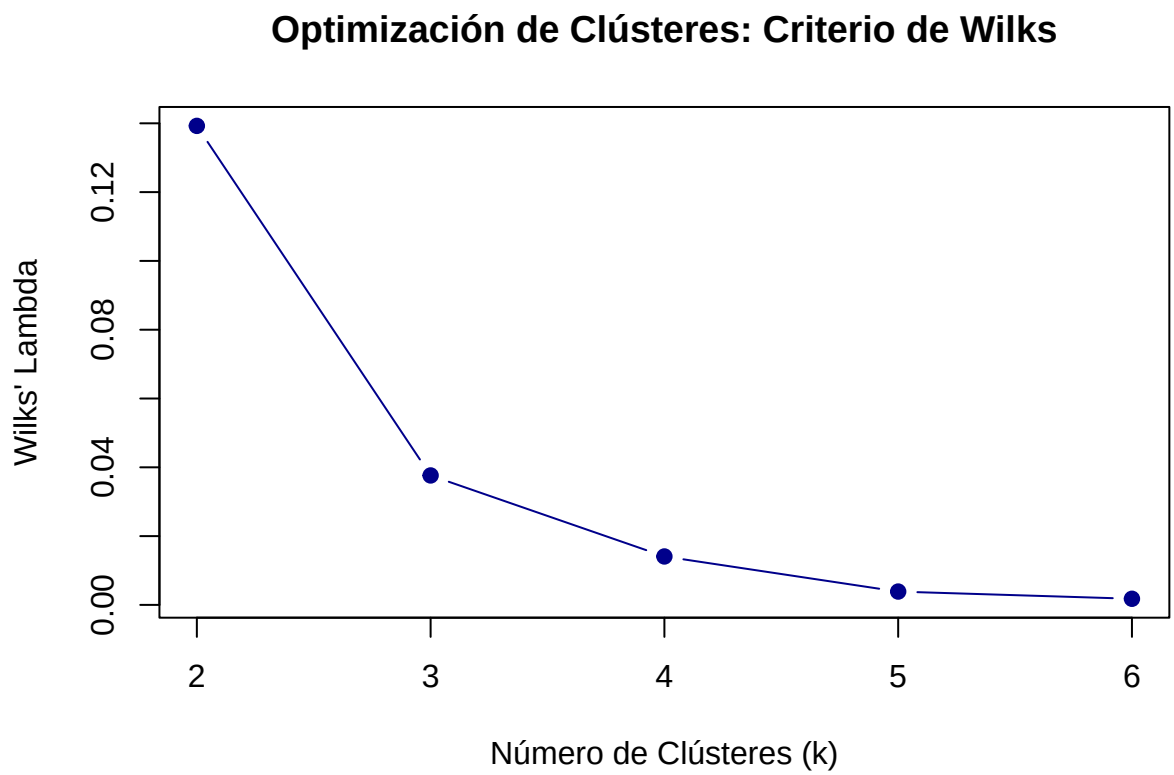


El estadístico $\Lambda$ de Wilks disminuye monótonamente conforme aumenta $K$. Se observa un "codo" o cambio de pendiente significativo al pasar de $K = 2$ a $K = 3$ (donde $\Lambda$ cae de aproximadamente 0.14 a 0.04). Esto garantiza que una partición de 3 grupos explica una porción sustancial de la varianza multivariante, validando estadísticamente la elección realizada en los puntos previos.

# 8 Conclusiones

1. **Consistencia**: Tanto el método jerárquico (Ward.D2) como el particionamiento (PAM) sugieren que la estructura óptima para el consumo de proteínas en Europa es de **3 grupos**.
2. **Robustez**: La validación con Wilks' Lambda confirma que $K = 3$ es el punto de equilibrio donde se maximiza la discriminación entre grupos sin sobre-segmentar los datos.
3. **Hallazgo Nutricional**: La división refleja la geografía europea (Norte/Oeste, Mediterráneo y Este), demostrando que la disponibilidad de alimentos y la cultura regional siguen siendo los principales predictores del perfil proteico nacional.

# 9 Repositorio

- iviterirambay/Clustering_Ejercicio_2